

Aprendizaje profundo aplicado a la microestructura de mercados de predicción: predicción de corto plazo en mercados de Bitcoin de Polymarket

Marc Maldonado Lorca
Universidad Politécnica de Madrid
maldonadolorcamarco@gmail.com

2026

Resumen

Estudiamos si las técnicas de aprendizaje profundo pueden explotar señales de microestructura para predecir el movimiento de corto plazo del precio de los contratos binarios sobre Bitcoin negociados en Polymarket. A diferencia de los trabajos centrados en la resolución del evento, nuestro objetivo son los movimientos locales del precio del contrato en ventanas de segundos, combinando el libro de órdenes con referencias externas del mercado de Bitcoin. Nuestra principal contribución es una metodología reproducible de captura de datos multi-fuente, validación estrictamente temporal y evaluación bajo costes de ejecución y latencia realistas. Mostramos empíricamente que un clasificador direccional con una precisión cercana al 90 % deja de ser rentable al introducir una latencia de entrada de dos segundos, lo que sitúa el coste y la ejecución — y no el acierto direccional — como el problema central. A partir de ese hallazgo evaluamos una progresión de modelos (baselines tabulares, modelos sensibles a la latencia, y arquitecturas secuenciales y convolucionales sobre el libro de órdenes) y un especialista tabular congelado, combinado con un filtro de volatilidad, que sobrevive a una validación fuera de muestra de cinco días (+1,069 ticks netos por operación, intervalo de confianza bootstrap del 90 % [+0,472, +1,654], cinco de cinco días positivos). Reportamos todos los resultados en ticks netos y acompañados de su soporte e incertidumbre, y no afirmamos rentabilidad real: la aportación es la metodología, la evidencia y la delimitación de sus límites.

Palabras clave: microestructura de mercado, mercados de predicción, libro de órdenes, aprendizaje profundo, validación temporal, costes de ejecución, cambio de distribución.

1. Introducción

Polymarket es un mercado de predicción descentralizado en el que se negocian contratos binarios sobre eventos futuros mediante un libro de órdenes con emparejamiento fuera de cadena y liquidación en cadena [2]. En los mercados sobre el precio de Bitcoin, el precio del contrato, acotado entre 0 y 1, se interpreta como una probabilidad implícita del evento [1]. Esta estructura permite tratar el mercado como un pequeño *exchange*, con bids, asks, spread, profundidad y flujo de órdenes, y plantea una pregunta de microestructura: ¿contiene el libro de órdenes señales explotables sobre el movimiento de corto plazo del precio del contrato?

El interés de este entorno reside en su naturaleza híbrida. El precio del contrato no es el precio de Bitcoin, sino una función no lineal y dependiente del tiempo de la probabilidad de que el evento se resuelva afirmativamente; sin embargo, está acoplado a referencias externas observables (mercados al contado y de derivados perpetuos, oráculos de precios). Un modelo de microestructura debe, por tanto, aprender simultáneamente la dinámica del libro y la semántica del contrato.

Una hipótesis recurrente en este tipo de trabajos es que un clasificador con buena precisión direccional constituye una estrategia rentable. Esta hipótesis es engañosa: una métrica de clasificación puede ser elevada y, aun así, el sistema no ser explotable si opera con retraso, aprende artefactos del conjunto de datos o ignora el coste real de la orden. El núcleo de este trabajo consiste en evaluar cada modelo no por su acierto, sino por su rendimiento económico bajo costes y latencia realistas.

Contribuciones. Este artículo presenta:

- un sistema de adquisición de datos multi-fuente con controles de calidad por sesión que produce un corpus alineado temporalmente (Sección 3);
- un protocolo de evaluación que combina validación estrictamente temporal, un modelo explícito de costes y latencia medida empíricamente, y la congelación del candidato antes de su validación fuera de muestra (Sección 4);
- evidencia cuantitativa de que la latencia, y no el acierto direccional, determina el resultado, junto con una progresión de modelos que delimita dónde se rompe la cadena entre predicción y ejecución (Sección 5);
- un candidato tabular congelado con filtro de volatilidad que sobrevive a una validación fuera de muestra bajo costes, así como un conjunto de experimentos de adaptación al cambio de régimen con resultado negativo, que reportamos por su valor metodológico (Sección 6).

2. Trabajo relacionado

2.1. Mercados de predicción

Los mercados de predicción se han estudiado como mecanismos de agregación de información dispersa. Wolfers y Zitzewitz [3] muestran que pueden producir previsiones precisas, si bien su interpretación depende del diseño del contrato, la liquidez y los incentivos de los participantes. La mayoría de esta literatura se centra en la calibración del precio frente a la resolución del evento. Nuestro objetivo es distinto y más cercano a la microestructura: la dinámica intradía del precio del contrato a escala de segundos, donde aparecen spreads, profundidad limitada y desalineaciones transitorias respecto a las referencias externas.

2.2. Aprendizaje profundo sobre libros de órdenes

La predicción de movimientos de precio a partir del libro de órdenes es un problema bien establecido. DeepLOB [4] propone una arquitectura que combina convoluciones para capturar la estructura espacial del libro con capas recurrentes para la dependencia temporal, evaluada sobre el conjunto de referencia FI-2010 [5]. Tsantekidis et al. [6] aplican redes convolucionales y recurrentes a la detección de cambios de precio en libros de órdenes. Sirignano y Cont [7] aportan evidencia de la existencia de características universales en la formación de precios aprendibles mediante aprendizaje profundo, y Jha et al. [8] trasladan estas ideas a criptoactivos. Estos trabajos justifican tratar el libro como un objeto con estructura espacio-temporal en lugar de como una tabla plana, pero suelen evaluar con métricas de clasificación y rara vez bajo un modelo de ejecución realista.

2.3. Microestructura, costes de ejecución y latencia

La distancia entre la predicción y la rentabilidad es un tema central de la microestructura. Kearns y Nevmyvaka [9] revisan el papel del aprendizaje automático en microestructura y negociación de alta frecuencia, y subrayan que la ejecución, el coste y la latencia condicionan de forma decisiva la viabilidad de una señal. Nuestro trabajo cuantifica este fenómeno en el

contexto de Polymarket: medimos la latencia real del ciclo de orden y mostramos que una señal direccional fuerte se vuelve no rentable bajo una latencia de entrada modesta.

2.4. Aprendizaje automático en finanzas y validación temporal

El aprendizaje automático aplicado a la predicción financiera es propenso a resultados ilusorios cuando la evaluación no respeta la estructura temporal. Gu, Kelly y Xiu [10] ofrecen un marco riguroso de comparación de modelos con validación fuera de muestra. López de Prado [11] documenta los mecanismos de fuga de información y de sobreajuste de *backtests* y propone protocolos de validación que respetan la causalidad temporal. Bailey y López de Prado [12] advierten sobre la inflación de métricas de rendimiento bajo selección múltiple de modelos. Estas referencias motivan nuestra elección de una partición estrictamente temporal, un protocolo *out-of-fold* y la congelación del candidato antes de observar el conjunto de validación fuera de muestra.

2.5. Cambio de distribución y adaptación de dominio

La no estacionariedad de los mercados financieros provoca cambios de distribución entre el periodo de entrenamiento y el de despliegue. Las técnicas de adaptación de dominio, como la alineación de correlaciones CORAL [13], buscan mitigar este efecto. En la Sección 6 mostramos que, con un horizonte de datos reducido, estas técnicas no superan a una estrategia más simple basada en restringir la operativa al régimen en el que el modelo fue entrenado.

3. Adquisición de datos y corpus

3.1. Sistema de captura multi-fuente

Desarrollamos un sistema de captura propio que registra, por sesión de mercado, el libro de órdenes de Polymarket, el flujo de operaciones, la metadata del mercado y referencias externas del mercado al contado y de derivados perpetuos de Bitcoin, así como un oráculo de precios. Las fuentes se alinean temporalmente sobre una malla regular de dos segundos. Esta elección no es accesorio: define el contrato de latencia utilizado en la evaluación, ya que en lugar de interpolar un instante no observado evaluamos contra la siguiente fotografía disponible del mercado.

3.2. Controles de calidad por sesión

Cada sesión se somete a controles de calidad antes de incorporarse al corpus: cobertura temporal, continuidad, proporción de datos obsoletos (*stale*), validación de arranque y detección de huecos severos. Las sesiones que no superan los umbrales se descartan. Esta separación entre sesiones válidas y rechazadas es deliberada: una referencia externa retrasada o incompleta puede inducir una señal espuria, y preferimos reducir el tamaño de la muestra antes que contaminar el entrenamiento.

3.3. Composición del corpus

El corpus principal abarca del 11 al 25 de mayo de 2026 (entrenamiento, validación y test terminal), con del orden de 2,6 millones de filas cross-venue. Como conjunto fuera de muestra reservamos del 6 al 10 de junio de 2026, capturado con posterioridad a la congelación del candidato (Sección 4). La unidad de observación es la tupla `sesión × token × instante` sobre la malla de dos segundos.

4. Formulación del problema y metodología

4.1. Definición del objetivo

Para cada instante t definimos el retorno futuro del precio medio a un horizonte H ,

$$\Delta_H = \frac{m_{t+H} - m_t}{m_t},$$

donde m_t es el precio medio del contrato. La etiqueta direccional se obtiene mediante un umbral θ que absorbe spread, comisiones y ruido,

$$y_t = \begin{cases} \text{UP} & \Delta_H > \theta, \\ \text{DOWN} & \Delta_H < -\theta, \\ \text{FLAT} & \text{en otro caso.} \end{cases}$$

Las características son causales y las etiquetas se calculan *a posteriori* de forma trazable, de modo que no se introduce información del futuro en las entradas del modelo. Todos los resultados económicos se expresan en *ticks* netos, la unidad natural del libro de órdenes; evitamos expresarlos en términos monetarios porque ello requeriría supuestos adicionales sobre el tamaño de posición y favorecería la sobreafirmación.

4.2. Validación temporal y prevención de fuga

La partición es estrictamente temporal: el entrenamiento utiliza las sesiones más antiguas, la validación las posteriores y el test terminal el bloque final. En los experimentos secuenciales empleamos además un protocolo *out-of-fold*: cada modelo se entrena únicamente con días anteriores, las predicciones que consume una segunda etapa son fuera de muestra, y la política de decisión se selecciona sin observar el test terminal. Esta disciplina contra la fuga temporal es la salvaguarda frente a resultados ilusorios [11, 10].

4.3. Modelo de costes y latencia

Medimos empíricamente la latencia del ciclo de orden de Polymarket en una prueba controlada. El tiempo desde la observación de la oportunidad hasta la confirmación de emparejamiento del libro fue de aproximadamente 0,43 segundos en el percentil 95 de la muestra válida. Por prudencia, fijamos una latencia conceptual de modelado de un segundo y una latencia observable en el conjunto de datos de dos segundos; esta última coincide con la malla de captura, lo que hace la evaluación conservadora. El coste de referencia por operación es de 0,5 ticks, con un contraste optimista de 0,25 ticks.

4.4. Protocolo de congelación

El candidato final — modelo, conjunto de características y umbrales de política — se congeló antes de observar el conjunto fuera de muestra del 6 al 10 de junio. Esta decisión convierte la validación posterior en una prueba fuera de muestra genuina en lugar de una nueva ronda de ajuste, y previene el sobreajuste por selección múltiple [12]. Una vez fijada, la política no se reajusta para mejorar los resultados.

5. Progresión experimental de modelos

Evaluamos una progresión incremental de modelos, de menor a mayor complejidad, exigiendo en cada paso que la complejidad adicional se justifique con evidencia de mejora bajo el mismo protocolo de costes y validación.

5.1. Baseline tabular y el impacto de la latencia

Un baseline tabular sobre el horizonte corto alcanza una precisión direccional cercana al 90 % y supera la validación temporal por bloques. Evaluado solo con métricas de clasificación, parece excelente. Sin embargo, al introducir la entrada retrasada y el coste, el panorama cambia radicalmente. La Tabla 1 reporta el rendimiento en el test terminal — el bloque no utilizado para seleccionar la política — en función de la latencia, en un escenario conservador con filtro de spread.

Latencia	Acciones	Acierto UP	Error DOWN	Neto medio	Neto total
0 s	64	92,19 %	1,56 %	+6,79	+434,44
2 s	63	39,68 %	44,44 %	−1,48	−93,48
4 s	66	45,45 %	43,94 %	−0,74	−48,83
8 s	66	43,94 %	31,82 %	−0,30	−19,53

Tabla 1: Rendimiento en el test terminal bajo distintas latencias (ticks). La señal a latencia nula es real como *markout* desde t , pero no sobrevive como política ejecutable con una latencia de 2 s.

El resultado es nuestra observación central: acertar la dirección no equivale a obtener beneficio. Con una latencia realista de dos segundos, el neto medio del test terminal cae a $-1,48$ ticks. En consecuencia, el problema deja de ser de clasificación y pasa a ser de ejecución, y a partir de aquí todo modelo se evalúa por su política económica bajo coste y latencia.

5.2. Modelos sensibles a la latencia

El siguiente paso incorpora la latencia en el etiquetado y la selección. Un modelo sensible a la latencia alcanzó un AUC de test de 0,79, pero su política económica seguía siendo negativa. La conclusión es coherente con la anterior: una mayor capacidad de clasificación no implica una política rentable.

5.3. Modelos secuenciales y convolucionales sobre el libro

Construimos secuencias de hasta ocho fotografías del mercado y un tensor del libro de órdenes de los diez primeros niveles, con forma $5\,831 \times 8 \times 10 \times 10$, auditado como completo y alineado. Sobre esta representación evaluamos modelos tabulares secuenciales, redes recurrentes (GRU), una red convolucional unidimensional sobre el libro siguiendo la intuición de DeepLOB [4, 6], fusiones de secuencia tabular y libro, y selectores de riesgo. Las arquitecturas recurrentes y de fusión mostraron señal de representación, y algunas políticas *proxy* resultaron positivas; sin embargo, dejaron de serlo al exigir selección causal, estabilidad diaria o modelado de ejecuciones parciales y adversas. Por tanto, no las consideramos candidatas finales. El aprendizaje profundo aporta representación, pero no una política rentable y estable con un horizonte de datos de aproximadamente quince días.

5.4. Corrección del score de selección adversa

Durante la auditoría de selección detectamos un error de interpretación: la variable objetivo de selección adversa, en la que el valor positivo denota un resultado desfavorable, se había empleado de forma que su probabilidad actuaba como puntuación descendente. La orientación correcta del score es $1 - P(\text{adverso})$. Marcamos los resultados afectados como superados y repetimos la validación con la orientación corregida; la candidata anterior dejó de constituir evidencia válida. Documentamos este episodio porque ilustra que una métrica positiva no es suficiente: es necesario auditar el significado económico de la puntuación que guía la selección.

5.5. Protocolo *out-of-fold* y selección de horizonte

Repetimos la fusión bajo un protocolo estrictamente fuera de muestra. La segunda etapa no produjo una política robusta, pero el modelo a horizonte H60 conservó una señal modesta (AUC de test 0,5656; rendimiento medio del 35 % superior tras coste 0,5 de +0,1778 ticks *proxy*). Para descartar que el problema fuera anticipar demasiado pronto, comparamos H60 frente a H120 con idénticas secuencias (Tabla 2).

Métrica	H60 emparejado	H120
AUC test	0,5651	0,4951
Top 35 % test, coste 0,5	+0,4262	−1,1171
Top 35 % test, coste 1,0	+0,0579	−1,4910

Tabla 2: Selección de horizonte (ticks). H120 se comporta de forma próxima al azar; H60 es el único que conserva señal. El horizonte H240 colapsa aún más en el conjunto fuera de muestra.

Los horizontes largos quedan descartados con evidencia: ampliarlos no mejora la señal. El estudio multi-horizonte se cierra y H60 se mantiene como único candidato.

5.6. Especialista de ventana *prestart*

El candidato final es un especialista para la ventana *prestart*: un modelo de *gradient boosting* sobre histogramas que combina un regresor de valor esperado y un clasificador de salud de sesión, sobre un conjunto de 36 características sin variables de reloj para evitar fugas temporales triviales. La señal se restringe a la ventana comprendida entre −60 y −45 segundos respecto a la apertura, con libro saludable y coste visible acotado. La política congelada selecciona operaciones con un valor esperado predicho superior a 0,75 y una probabilidad de salud no inferior a 0,50.

5.7. Filtro de volatilidad

Al preparar la validación fuera de muestra observamos un cambio de régimen: la fracción de sesiones de alta volatilidad pasó de un 18–22 % en el corpus de entrenamiento a aproximadamente un 58 % en el conjunto fuera de muestra (Tabla 3). El modelo se entrenó en un régimen de baja volatilidad y sus predicciones en alta volatilidad no son fiables bajo la distribución desplazada. Introducimos un filtro simple de volatilidad que solo habilita la operativa cuando la volatilidad realizada a 5 segundos no supera el umbral 0,6657, correspondiente al percentil 80 de la volatilidad de entrenamiento.

Periodo	Fracción alta volatilidad	Efecto del filtro
Entrenamiento (11–20 may)	22 %	marginal
Validación (21–22 may)	21 %	marginal
Test (23–25 may)	18 %	marginal
Fuera de muestra (6–10 jun)	58 %	determinante (+0,73)

Tabla 3: El cambio de régimen entre entrenamiento y conjunto fuera de muestra justifica el filtro de volatilidad.

6. Resultados

6.1. Validación fuera de muestra

Sobre los cinco días del conjunto fuera de muestra (6–10 de junio de 2026), con el candidato congelado y el filtro de volatilidad, obtenemos los resultados de la Tabla 4. El intervalo de

confianza es bootstrap con 5 000 remuestreos y semilla fija; la probabilidad de neto positivo se estima sobre la misma distribución de remuestreo.

Métrica	Valor
Operaciones (n)	318
Días de soporte	5 (5/5 positivos)
Neto medio (coste 0,5)	+1,069 ticks
Neto medio (coste 0,25)	+0,819 ticks
Intervalo de confianza 90 %	[+0,472, +1,654]
$P(\text{neto} > 0)$ (bootstrap)	99,8 %
Drawdown máximo	88,1 ticks
Neto medio sin filtro de volatilidad	+0,349 ticks

Tabla 4: Validación fuera de muestra del candidato congelado (ticks netos por operación). El filtro de volatilidad aporta +0,72 ticks, la mayor parte de la ventaja, precisamente por el cambio de régimen observado.

El soporte es de cinco días. Se trata de un soporte reducido y lo reportamos explícitamente junto a cada resultado. El filtro de volatilidad aporta la mayor parte de la ventaja porque el régimen del conjunto fuera de muestra difiere del de entrenamiento; sin él, el neto medio desciende a +0,349 ticks.

6.2. Experimentos de adaptación al régimen

Evaluamos varias estrategias para adaptar el modelo al nuevo régimen: reentrenamiento incremental con ventana móvil, alineación de correlaciones CORAL [13], un filtro conformal, un *ensemble* por *bootstrap*, un filtro de volatilidad adaptativo, características normalizadas por volatilidad y *distillation* de una red convolucional temporal. Ninguna superó de forma robusta al modelo congelado con el filtro simple. Reportamos este resultado negativo porque es informativo: con un horizonte de datos reducido, la combinación de un modelo congelado y un filtro simple supera a la adaptación de dominio sofisticada, que requiere más datos de los disponibles para estimarse de forma fiable.

6.3. Seguimiento *paper-shadow*

La infraestructura de evaluación final es un registro *paper-shadow*: contabilidad operación a operación, resumen diario y reglas de promoción cuantitativas. Las reglas son deliberadamente conservadoras y exigen soporte temporal, no solo neto positivo: la promoción a candidato de seguimiento requiere un neto superior a 0,5 ticks, al menos 200 operaciones y al menos 8 días. Con cinco días, el candidato permanece en estado *prometedor pero con datos insuficientes*, por falta de soporte temporal y no por ausencia de señal. Forzar la promoción en este punto sería metodológicamente incorrecto.

7. Discusión y limitaciones

El límite principal de este trabajo es el soporte temporal del conjunto fuera de muestra: cinco días. Aunque el intervalo de confianza es estrecho y los cinco días son positivos, cinco días no constituyen una validación definitiva, y así lo reportamos. El resultado es además específico de la ventana *prestart* y del régimen capturado; un cambio de régimen suficientemente grande podría invalidar el filtro de volatilidad, como ilustra el propio desplazamiento observado entre el entrenamiento y el conjunto fuera de muestra. Finalmente, la validación es *offline* bajo un modelo de ejecución conservador pero simplificado; una validación con ejecución simulada de mayor fidelidad (ejecuciones parciales, dinámica de cola) es trabajo pendiente.

Observamos también un patrón en forma de U en la relación entre volatilidad y beneficio dentro del intervalo habilitado por el filtro, en el que la volatilidad muy baja concentra la mayor parte del beneficio. Dado que descansa sobre cinco días, lo dejamos como hipótesis a validar y no como resultado.

8. Consideraciones éticas

El sistema toma decisiones económicas automatizadas y es especialmente sensible al sobreajuste cuando el horizonte de datos es reducido. Por ello el trabajo se detiene deliberadamente en la fase de *paper-shadow* y no opera con capital real. Adoptamos un marco de confidencialidad, integridad y disponibilidad, y tratamos la integridad de los datos como tan crítica como el propio modelo: una referencia externa retrasada o errónea puede inducir una señal espuria y, con ella, una pérdida. En consecuencia, el sistema se entrena únicamente con sesiones aceptadas, separa los datos crudos de las características y las etiquetas, mantiene trazabilidad de los artefactos y define umbrales para inhibir la operativa ante datos obsoletos. El trabajo no emplea datos personales: utiliza exclusivamente datos públicos de mercado.

9. Conclusiones

Hemos presentado una metodología completa de captura de datos, validación temporal y control de costes para la predicción de corto plazo en los mercados de Bitcoin de Polymarket. Nuestra observación central es que los clasificadores direccionales, pese a una precisión cercana al 90 %, dejan de ser rentables bajo una latencia de entrada realista: el coste y la ejecución, y no el acierto, determinan el resultado. El aprendizaje profundo sobre secuencias y libro de órdenes aporta capacidad de representación, pero no una política rentable y estable con un horizonte de datos de unas dos semanas. Un especialista tabular congelado, combinado con un filtro de volatilidad, sí sobrevive a una validación fuera de muestra de cinco días (+1,069 ticks netos por operación, cinco de cinco días positivos), y queda en seguimiento *paper-shadow* con reglas de promoción cuantitativas. No afirmamos rentabilidad real: la aportación de este trabajo es la metodología, la evidencia obtenida bajo un protocolo honesto y la delimitación explícita de sus límites. Como trabajo futuro proponemos ampliar el soporte temporal del conjunto fuera de muestra, validar el patrón en U de la volatilidad y reevaluar las arquitecturas profundas con un horizonte de datos sustancialmente mayor, condicionado a que superen al especialista tabular bajo el mismo protocolo. El código, los registros de resultados y los artefactos necesarios para reproducir el trabajo se publican junto a este artículo, siguiendo prácticas de trazabilidad que mitigan la deuda técnica inherente a estos sistemas [15].

Referencias

- [1] Polymarket Documentation. *Prices & Orderbooks*. <https://docs.polymarket.com/polymarket-learn/trading/using-the-orderbook>
- [2] Polymarket Documentation. *Order Lifecycle*. <https://docs.polymarket.com/concepts/order-lifecycle>
- [3] J. Wolfers and E. Zitzewitz. *Prediction Markets*. Journal of Economic Perspectives, 18(2), 107–126, 2004.
- [4] Z. Zhang, S. Zohren and S. Roberts. *DeepLOB: Deep Convolutional Neural Networks for Limit Order Books*. IEEE Transactions on Signal Processing, 67(11), 3001–3012, 2019.

- [5] A. Ntakaris, M. Magris, J. Kannianen, M. Gabbouj and A. Iosifidis. *Benchmark dataset for mid-price forecasting of limit order book data with machine learning methods*. Journal of Forecasting, 37(8), 852–866, 2018.
- [6] A. Tsantekidis, N. Passalis, A. Tefas, J. Kannianen, M. Gabbouj and A. Iosifidis. *Using deep learning to detect price change indications in financial markets*. European Signal Processing Conference (EUSIPCO), 2017.
- [7] J. Sirignano and R. Cont. *Universal features of price formation in financial markets: perspectives from deep learning*. Quantitative Finance, 19(9), 1449–1459, 2019.
- [8] R. Jha et al. *Deep Learning for Digital Asset Limit Order Books*. arXiv:2010.01241, 2020.
- [9] M. Kearns and Y. Nevmyvaka. *Machine Learning for Market Microstructure and High Frequency Trading*. In High Frequency Trading: New Realities for Traders, Markets and Regulators, 2013.
- [10] S. Gu, B. Kelly and D. Xiu. *Empirical Asset Pricing via Machine Learning*. The Review of Financial Studies, 33(5), 2223–2273, 2020.
- [11] M. López de Prado. *Advances in Financial Machine Learning*. Wiley, 2018.
- [12] D. H. Bailey and M. López de Prado. *The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality*. The Journal of Portfolio Management, 40(5), 94–107, 2014.
- [13] B. Sun, J. Feng and K. Saenko. *Return of Frustratingly Easy Domain Adaptation*. AAAI Conference on Artificial Intelligence, 2016.
- [14] B. Lim, S. O. Arik, N. Loeff and T. Pfister. *Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting*. International Journal of Forecasting, 37(4), 1748–1764, 2021.
- [15] D. Sculley et al. *Hidden Technical Debt in Machine Learning Systems*. Advances in Neural Information Processing Systems (NeurIPS), 2015.